

Wissensentdeckung in Datenbanken SoSe 2018

Lösungsvorschlag Übungsblatt 01

Sebastian Buschjäger, Malte Jastrow

Aufgabe 1

a)

Stichprobenraum

$$\Omega = \{\text{Kopf}, \text{Zahl}\}$$

Sigma-Algebren:

$$\mathfrak{A}_1 = \{\emptyset, \Omega\}$$

$$\mathfrak{A}_2 = \{\emptyset, \{\text{Kopf}\}, \{\text{Zahl}\}, \Omega\}$$

Offensichtlich ist nur \mathfrak{A}_1 spannend. Weniger spannend ist es hier tatsächlich mal die Bedingungen einer σ -Algebra nachzurechnen. Die Eigenschaften einer Ereignisalgebra gelten offensichtlich immer, die zusätzlichen Eigenschaften ergeben sich direkt aus den Fallunterscheidungen $\emptyset \in A$ und $\Omega \in A$. Falls $\emptyset \in A$ ist, so ist der unendliche Schnitt auch immer \emptyset , also in der σ -Algebra. Falls nur Kopf oder nur Zahl und evtl. Ω enthalten sind, ist der Schnitt Kopf bzw. Zahl, also auch enthalten. Wenn sowohl Kopf als auch Zahl enthalten sind, ist der Schnitt wieder leer, was auch enthalten ist. Wenn nur Ω in der Folge enthalten ist, ist der Schnitt auch Ω , damit sind alle möglichen Fälle abgedeckt. Die Eigenschaft über die Vereinigung folgt analog.

b)

Wahrscheinlichkeitsfunktion:

$$P(\emptyset) = 0$$

$$P(\{\text{Kopf}\}) = 0.5$$

$$P(\{\text{Zahl}\}) = 0.5$$

$$P(\Omega) = 1$$

Sei im Folgenden Kopf mit 0 und Zahl mit 1 kodiert. Empirische Verteilungsfunktion:

$$F_X(x) = \begin{cases} 0, & \text{falls } x < 0, \\ 0.5, & \text{falls } 0 \leq x < 1 \end{cases}$$

Wahrscheinlichkeitsfunktion:

$$P(\emptyset) = 0$$

$$P(\{\text{Kopf}\}) = 0.5$$

$$P(\{\text{Zahl}\}) = 0.5$$

$$P(\Omega) = 1$$

Sei im Folgenden Kopf mit 0 und Zahl mit 1 kodiert. \ Empirische Verteilungsfunktion:

$$F_X(x) = \begin{cases} 0, & \text{falls } x < 0, \\ 0.5, & \text{falls } 0 \leq x < 1, \\ 1, & \text{falls } x \geq 1. \end{cases}$$

Empirische Dichtefunktion

$$f_X(x) = \begin{cases} 0.5, & \text{falls } x \in \{0, 1\}, \\ 0, & \text{sonst.} \end{cases}$$

c)

Erwartungswert

$$E(X) = f_X(0) \cdot 0 + f_X(1) \cdot 1 = 0.5.$$

Varianz

$$\text{Var}(X) = (0 - 0.5)^2 \cdot f_X(0) + (1 - 0.5)^2 \cdot f_X(1) = 0.5^2 \cdot 0.5 + 0.5^2 \cdot 0.5 = 0.25$$

Die Zufallsvariable ist Bernoulli-verteilt mit Parameter $p = 0.5$: $X \sim B(0.5)$. Der Erwartungswert beträgt dementsprechend p , die Varianz $p \cdot (1 - p)$.

d)

Erwartungswert der Summe

$$E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = \sum_{i=1}^n E(X) = n \cdot E(X_i) = 0.5 \cdot n = \frac{n}{2}$$

Varianz der Summe

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n \text{Var}(X) = n \cdot \text{Var}(X_i) = 0.25 \cdot n = \frac{n}{4}$$

Die erste Gleichheit gilt dabei nur, weil die Zufallsvariablen X_i paarweise unkorreliert sind. Die Summe ist Binomialverteilt. Die Bernoulli-Verteilung ist ein Spezialfall der Binomialverteilung mit $n = 1$.

Aufgabe 2

a)

```
measures <- list(mean, var, median, min, max)
measure.names <- c("mean", "var", "median", "min", "max")
res1 <- sapply(measures, function(measure) apply(iris[, 1:4], 2, measure))
colnames(res1) <- measure.names
res1
```

```
##           mean      var median min max
## Sepal.Length 5.843333 0.6856935   5.80 4.3 7.9
## Sepal.Width  3.057333 0.1899794   3.00 2.0 4.4
## Petal.Length 3.758000 3.1162779   4.35 1.0 6.9
## Petal.Width  1.199333 0.5810063   1.30 0.1 2.5
```

```
table(iris$Species)
```

```
##
##      setosa versicolor virginica
##      50      50      50
```


Aufgabe 4

a)

$$\begin{aligned}P(\|X\| < 1) &= P(\sqrt{X_1^2 + X_2^2} < 1) \\&= P(X_1^2 + X_2^2 < 1) \\&= P(X_1^2 < 1 - X_2^2) \\&= P(-\sqrt{1 - X_2^2} < X_1 < \sqrt{1 - X_2^2}) \\&= \int_{-1}^1 \int_{-\sqrt{1-x_2^2}}^{\sqrt{1-x_2^2}} \frac{1}{4} dx_1 dx_2 \\&= \int_{-1}^1 \left[\frac{x_1}{4} \right]_{-\sqrt{1-x_2^2}}^{\sqrt{1-x_2^2}} dx_2 \\&= \int_{-1}^1 \frac{2}{4} \sqrt{1-x_2^2} dx_2 \\&= \frac{1}{2} \int_{-1}^1 \sqrt{1-x_2^2} dx_2 \\&= \int_0^1 \sqrt{1-x_2^2} dx_2 \text{ (Tipp)} \\&= \left[\frac{\arcsin(x)}{2} + \frac{x\sqrt{1-x^2}}{2} \right]_0^1 \\&= \frac{\pi}{4}\end{aligned}$$

b)

Aus a) folgt:

$$\pi = 4 \cdot P(\|X\| < 1)$$

mit dem angegebenen erwartungstreuen Schätzer ergibt sich daraus:

$$\hat{\pi} = 4 \cdot h_n(\mathbf{x})$$

$$\begin{aligned}
 &= \int_0^1 \sqrt{1-x^2} dx \\
 &= \left[\frac{\arcsin(x)}{2} + \frac{x\sqrt{1-x^2}}{2} \right]_0^1 \\
 &= \frac{\pi}{4}
 \end{aligned}$$

b)

Aus a) folgt:

$$\pi = 4 \cdot P(\|X\| < 1)$$

mit dem angegebenen erwartungstreuen Schätzer ergibt sich daraus:

$$\hat{\pi} = 4 \cdot h_n(x)$$

Der Schätzer $\hat{\pi}$ ist erwartungstreu, da:

$$\begin{aligned}
 E(\hat{\pi}) &= E(4 \cdot h_n(x)) \\
 &= 4 \cdot \frac{\pi}{4} \text{ (weil } h_n(x) \text{ erwartungstreu ist)} \\
 &= \pi
 \end{aligned}$$

c)

```
piHat <- function(n){
  4 * mean(apply(matrix(runif(2 * n, -1, 1), 2), 2, crossprod) < 1))
}
```

```
set.seed(1273)
```



```

ns <- c(10, 20, 50, 100, 1000, 5000, 10000)
res <- sapply(ns,
  function(n) {
    tmp <- replicate(100, piHat(n))
    return(t.test(tmp)$conf.int)
  }
)

```


Visualisierung:


```

plot(c(1, 1), res[, 1], xlim = c(1, 7), ylim = range(res), type = "l",
  xlab = "n", ylab = "Confidence Interval", xaxt = "n", lwd = 2,
  main = expression(paste("Estimation of ", pi)))
axis(1, at = 1:7, labels = ns)
for (i in 2:7)
  lines(c(i, i), res[, i], type = "l", lwd = 2)
abline(h = pi, col = "red")

```

Estimation of π





Die Schätzung scheint Erwartungstreu zu sein (Rote Linie in jedem KI), KIs werden mit steigendem n immer kleiner. Achtung: n ist die Anzahl Zufallszahlen zur Bestimmung von π , nicht die Replikationszahl.

Es zeigt sich wie erwartet: Im Mittelwert wird π ungefähr getroffen, mit steigendem n nimmt die Varianz ab.